

DreamLite 限时全量级训练实验报告

1. 结论摘要

判定项	结果	说明
训练执行	通过	进程正常退出， <code>exit_code=0</code> ，256 个 optimizer steps 全部完成
3–4 小时 时间预算	通过	训练器计时 3:07:14；终端墙钟 3:07:36
全量级机制	通过	使用完整 DreamLite + Qwen Reader、1024 分辨率、4-step DreamLite、whole-episode BPTT 和正式数据源
原始正式矩阵	未完成，符合本次缩减约束	单 seed、2048/5000 个训练 episode（40.96%），未执行多 seed、完整 epoch 或 ID/OOD 矩阵
学习趋势	弱 / 不确定	首末 32 步 loss 均值仅下降 2.13%，中位数反而上升 1.99%，没有清晰收敛趋势
科学测评结论	不可判定	仅在末步测了固定 8 个 dev episode × 4 个 choice views；没有 step-0 dev baseline，也没有独立 ID/OOD scientific gate

本次实验在工程层面成功：完整训练链路、正式数据、检查点、指标和可复现信息均正常产出，并将总时间控制在 3–4 小时内。但现有证据不足以证明 DreamLite 已经学到稳定有效的更新策略。最明显的优化风险是：256/256 个更新的裁剪前梯度范数都高于阈值 1.0，最后一步达到 `27,106,712`，训练处于持续梯度裁剪状态。

2. 实验目标与范围

目标是跳过耗时的分层测评，直接在正式数据源上运行 DreamLite 完整训练机制，观察 loss、梯度、吞吐和显存，并把总实验时长限制为 3–4 小时。

本报告中的“限时全量级”指：

- 完整模型与完整训练机制，不降低 DreamLite 分辨率或 denoising steps；
- 从正式 5000 条 train pool 全量加载并确定性 shuffle，不截取有序前缀；
- 用最大 optimizer steps 限制时间，因此实际消费 2048 条、占正式 train pool 的 40.96%；
- 只跑 seed 0 和一个 QA-only 主臂；
- 仅做一次末端小规模 dev 观测，不复现原三种子、两轮训练和完整 ID/OOD 矩阵。

因此，本次结果适合回答“完整 DreamLite 训练能否在 3–4 小时稳定跑通、loss 是否表现出初步学习迹象”，不适合替代正式统计实验。

3. 运行环境与可复现信息

项目	值
Inspire 实例	<code>vlm-dreamlite-full-h200x2-20260720</code>
节点 / 算力组	<code>qb-prod-gpu1930 / 开发区-H200-3号机房</code>

项目	值
GPU	2 × NVIDIA H200 SXM 141 GiB
CPU / RAM / SHM	40 CPU / 400 GiB / 128 GiB
镜像	ngc-pytorch:25.02-cuda12.8.0-py3
Python / PyTorch / CUDA	3.12.3 / 2.7.0a0+nv25.02 / 12.8
代码提交	10bde565d30d119a68e8460757d979b1c35e1b8f，worktree clean
运行 ID	dreamlite-fullscale-formal-v1-seed0-20260720-10bde56
启动时间（北京时间）	2026-07-20 02:35:37
完成时间（北京时间）	2026-07-20 05:43:13
终端状态	succeeded, passed=true, exit_code=0

严格确定性模式已启用，包括 deterministic algorithms、关闭 TF32、固定 Python/CUDA 随机源并使用 math SDPA。两张 GPU 分工为 DreamLite `cuda:0`、Qwen Reader `cuda:1`；当前 trainer 不使用 DDP，因此增加 GPU 数量不会加速单训练臂。

数据与模型指纹

工件	SHA256 / revision
formal-v1 train (5000)	24327edc39e0d133df5150dc1aab4f55c6cf5b05ccfca9025ad90c5accc6d184
formal-v1 dev (500)	8b167df38022a631d4e631d3c0d66e9fca74171f4224fec436030d6650047303
formal-v1 manifest	089beeфа00b9b78149b3d7f4bd40cf802dc2c92a3757c04f30d9534bbdc51215
DreamLite revision	6695c3f4be230f0493fa5dbf78be3bc4d3bb2ab4
DreamLite snapshot manifest	1bcf41b170c4b4a806bac6701cbdf4fabd5c3c53fa67415d065ab95ce2703159
Qwen Reader revision	ebb281ec70b05090aa6165b016eac8ec08e71b17
Qwen snapshot manifest	159a504daaae6dc412535978f087150a0eb8e50164afd70a8a17f83906f1127c
preflight	056b39959c8ae8d5cc9a8006e3b03d49f3cb1f59ef4b31984d5a42e28781dfc9
launcher configuration	bfe78ee4529f34d25b61c574da33e5077d7080db3776115295c034e6c1e1286a

4. 训练配置

参数	设置
regime / objective	qa_only / qa
Reader loss	listwise-choice
choice schedule	cyclic4；dev 使用 reverse cyclic4 四视图

参数	设置
recurrence	<code>direct_latent</code> ，不 detach events
curriculum / noop policy	<code>full</code> / <code>update</code>
initial state	1024×1024 中性灰 blank fixture
seed / adapter seed	0 / 0
LoRA rank / 可训练参数	4 / 1,644,544
optimizer steps	256
gradient accumulation	8 episodes / step
实际训练 episode	2048，正式 train pool 的 40.96%
learning rate / weight decay	<code>1e-4</code> / <code>0.01</code>
gradient clip	global norm <code>1.0</code>
checkpoint	每 8 步，共 32 个周期检查点，另有 <code>best.pt</code> 和 <code>last.pt</code>
dev	仅 step 256；8 episodes × 4 views = 32 次视图评估


5. 主要结果


指标	结果
optimizer steps	256
训练 episode presentations	2048
最后一步 train loss	14.4677
唯一一次 / 最优 dev loss	10.0845
全程 train loss 均值 / 中位数 / 标准差	14.3718 / 14.2466 / 3.0215
loss OLS 斜率 / Pearson r	-0.002179 每步 / -0.0534
首 32 步 loss 均值	14.2365
末 32 步 loss 均值	13.9335
首末均值变化	-2.13%
首 32 步 loss 中位数	13.7783
末 32 步 loss 中位数	14.0529
首末中位数变化	+1.99%
裁剪前梯度中位数	17,250.46
裁剪触发率	256/256 = 100%
裁剪前梯度最大值	27,106,712 (step 256)

指标	结果
训练器耗时	11,233.80 秒 = 3:07:14
纯训练累计耗时	11,179.35 秒
平均 optimizer step	43.67 秒
平均单 episode	5.46 秒
吞吐	0.1832 episode/s
峰值显存	cuda:0 21.16 GiB; cuda:1 21.39 GiB

每 32 步窗口统计

optimizer steps	loss mean	loss median	loss min	loss max	raw grad median	raw grad max
1–32	14.2365	13.7783	9.7063	21.0319	11,839	1,039,446
33–64	14.8406	15.0022	9.4939	21.5287	20,667	749,078
65–96	14.1675	13.3347	8.1111	21.4458	9,534	983,802
97–128	15.2154	15.0145	8.1654	22.1397	13,023	186,763
129–160	14.4144	14.6444	8.3367	18.8850	18,325	316,645
161–192	13.8126	13.8080	7.6901	20.8284	14,500	2,908,102
193–224	14.3536	14.2071	7.9737	24.7281	34,983	309,537
225–256	13.9335	14.0529	9.6166	19.2445	19,809	27,106,712





6. 结果解释

6.1 工程结论

完整 DreamLite 训练在 2×H200 上稳定执行了 256 个更新，没有 OOM、NaN/Inf、进程崩溃或检查点中断。3–4 小时预算可支持约 2048 个正式 episode presentations，且 32 个周期检查点均成功保存。因此，当前代码和环境足以支持后续定向实验。

峰值显存只有约 21.4 GiB/卡，远低于 H200 的 141 GiB。这里说明显存不是当前限制，但本次没有采集 SM 利用率，不能仅凭显存数据判断算力利用率。严格确定性 math kernels、4-step DreamLite 和逐 episode Reader 前向共同决定了当前约 0.183 episode/s 的吞吐。

6.2 学习结论

loss 的 EMA 在早期下降后长期围绕 14 高噪声振荡。首末窗口均值下降 2.13%，但中位数上升 1.99%；各 32 步窗口也没有单调改善。全程 OLS 斜率只有 $-0.002179/\text{step}$ ，Pearson $r=-0.0534$ ，说明 step 与 loss 几乎没有稳定线性关系。因此，现阶段只能认为存在很弱的均值变化，不能称为收敛。

10.0845 是 step 256 唯一一次 dev loss，也因此被程序记为 `best_dev_loss`。由于没有相同 dev slice 上的 step-0 baseline，不能据此计算泛化改进；8/500 的 dev 覆盖率也只有 1.6%。

梯度是更强的风险信号：所有更新都触发 global-norm clip，最后一步的裁剪前范数比总体中位数高约 1571 倍。step 256 的 train loss 本身并非离群点，说明裁剪至少抑制了即时 loss 爆炸；这不等于已经发生数值发散。但持续裁剪和重尾梯度表明优化过程由 clip 主导，当前 $lr=1e-4$ 、loss 尺度或梯度传播路径值得进一步诊断。

7. 局限

- 没有 step-0 dev baseline；无法量化训练前后改善。
- 只在 step 256 评估一次，无法判断最佳点是否更早出现。
- dev 只使用固定 8/500 episodes，尚未覆盖 ID/OOD test。
- 只有 seed 0，不能给出方差或稳定性结论。
- 正式 train pool 只消费 2048/5000；没有完成完整 epoch，更没有原正式矩阵的两轮训练。
- `state_gradient_audit` 本次按限时方案关闭；已有 raw global gradient norm，但没有逐状态张量的梯度审计。
- 未采集 GPU SM 利用率、功耗和 kernel profile；只能报告端到端吞吐与峰值显存。
- 启动器没有生成独立 stage-evidence/scientific-gate 文件，所以自动报告能证明 terminal 与日志哈希一致，但不会把本次标为“strict scientific complete”。

8. 建议的最小后续实验

1. **先做 checkpoint-only 评估，不立即重跑长训练。** 在完全相同的固定 dev slice 上测未训练初始化，以及 steps 64、128、192、256 四个检查点。这样能低成本补出真正的学习曲线和 step-0 baseline。
2. **诊断持续裁剪。** 增加 post-clip norm、update/weight ratio 和按模块梯度统计；先用 32–64 步短跑比较 $lr=1e-4$ 与 $3e-5$ 。不建议在原因未明时直接放大 clip 阈值。
3. **只有在 checkpoint dev 曲线显示改善时再扩量。** 届时优先扩到完整 5000 presentations 或增加一个 seed，而不是马上恢复整个多臂分层矩阵。
4. **补 scientific gate。** 固定 dev/ID/OOD slice、明确 baseline 与容差，并把 gate 输出绑定到 terminal，之后自动报告即可通过 strict-complete 校验。

9. 工件与审计入口

- [自动生成的单文件 HTML 报告](#)
- [自动生成的 Markdown 报告](#)
- [训练曲线 CSV](#)
- [机器可读报告摘要](#)
- [完整 SHA256 清单](#)
- [原始 metrics.jsonl 副本](#)
- [terminal.json 副本](#)
- [训练失效诊断可视化 HTML](#)
- [训练失效诊断 Markdown](#)
- [训练失效诊断机器摘要](#)
- [训练失效诊断 SHA256 清单](#)

原始自动报告基线共 20 个文件，仍由 `artifacts.sha256` 逐一校验且未被改写。新增诊断数据、图表和报告使用独立的 `diagnostic_artifacts.sha256`，避免改变基线证据含义。远端原始运行目录为：

```
/inspire/ssd/project/exploration-topic/czxs26210936/runs/vision-language-memory-r3/dreamlite-fullscale-formal-v1-seed0-20260720-10bde56
```

自动证据包保存在该目录的 `report-v1/`；本地镜像保存在 `runs/formal_reports/dreamlite-fullscale-formal-v1-seed0-20260720-10bde56/`。

10. 训练失效诊断补充

10.1 分析单位与证据边界

已按训练代码中的 `episode_order(seed=0, epoch=0)` 重建实际 shuffle 顺序，并将前 2048 条 episode 与 256 条 train metrics 精确对齐。所有 metrics 的 `episode_cursor` 均等于 `optimizer_step × 8`，正式 train 文件 SHA256 与 manifest 完全一致，5000 条 episode 的 schema、反事实链接、clean/NOOP 链接和 mixed-delayed probe 结构检查均通过。

需要特别强调：原 run 每 8 条 episode 才记录一次 group mean loss 和一次累积后的 raw global gradient norm。因此，本节以 **8-episode 梯度累积组**为独立统计单位。旧日志不能恢复逐 episode 梯度，也不能恢复各 LoRA block 的梯度；异常审计只能先锁定候选组，不能把组级梯度虚假分摊给组内样本。

实际消费数据的路由构成为：

项目	分布
updater calls / episode	2 次：1019；3 次：1029
reader queries / episode	2 次：1015；3 次：1033
mixed / separate	1033 / 1015
topic	color 360；drink 377；material 361；meal 301；music 316；style 333
实际事件序列	<code>set→set</code> 497； <code>set→overwrite</code> 395； <code>set→noop→overwrite</code> 377； <code>set→set→noop</code> 276； <code>set→noop→set</code> 251； <code>set→clear</code> 127； <code>set→noop→clear</code> 125
delayed probe	2048/2048 均存在，因而没有 non-delayed 对照


10.2 事件类型 × update 次数 × 梯度

以 `log10(raw global gradient norm)` 为因变量、256 个累积组为独立样本，得到以下探索性关联。置信区间由固定 seed 2026 的 10,000 次 group bootstrap 得到；`Holm p` 同时校正 21 个事件、主题、loss 和阶段特征。


组级特征	Spearman p	95% bootstrap CI	raw p	Holm p
平均 updater calls	+0.134	[0.008, 0.256]	0.0316	0.6004
mixed episode 数	-0.026	[-0.147, 0.097]	0.6813	1.0000

组级特征	Spearman ρ	95% bootstrap CI	raw p	Holm p
SET 事件数	+0.138	[0.014, 0.255]	0.0272	0.5429
OVERWRITE 事件数	-0.065	[-0.188, 0.056]	0.2989	1.0000
CLEAR 事件数	-0.108	[-0.237, 0.019]	0.0834	1.0000
NOOP 事件数	+0.134	[0.010, 0.256]	0.0316	0.6004
group loss	+0.102	[-0.016, 0.215]	0.1032	1.0000
optimizer step	+0.150	[0.031, 0.268]	0.0165	0.3458

没有组成特征在多重校正后达到 0.05。SET 是所有 episode 的初始状态建立事件，无法形成“无 SET”对照；NOOP 数、3-update episode 数、turn 数和 distractor 数由数据生成规则结构性绑定，因此不能用这份旧日志把它们分别解释成独立原因。




组 loss 与梯度仅弱相关。最高 loss 的 step 200 为 24.7281，但 raw gradient 只有 22,549.7；最高梯度的 step 256 loss 为 14.4677，并不是 loss 异常组。这反驳了“最难样本组自然产生最大梯度”的简单解释。



10.3 训练阶段

optimizer steps	loss mean	loss median	raw grad median	raw grad P90	raw grad max
1–64	14.5385	14.2951	18,556	99,787	1,039,446
65–128	14.6914	14.4727	10,311	117,323	983,802
129–192	14.1135	14.2942	16,821	114,662	2,908,102
193–256	14.1436	14.1633	24,709	268,440	27,106,712

四阶段梯度分布的 Kruskal-Wallis $p=0.03285$ ，loss 的对应值为 $p=0.79132$ 。 $\log_{10}(\text{raw gradient})$ 的 Theil-Sen 每步斜率为 $+0.001387$ ，95% CI $[+0.000266, +0.002560]$ 。梯度不是逐阶段单调上升，但末四分位的中位数、P90 和极端尾部均明显抬升，而 loss 没有同步恶化，说明参数轨迹或反向传播尺度比数据难度更值得优先排查。




10.4 哪些任务实际在学习

使用 256 个独立组拟合条件线性 loss 趋势，并控制事件序列、mixed 比例和 choice rotation；以下数值表示模型估计的 step 1→256 loss 变化：

topic	建模 loss 变化	95% group-bootstrap CI	可判定学习
color	+2.872	[-4.517, +9.674]	否
drink	+2.587	[-3.741, +9.054]	否
material	-0.322	[-6.162, +5.420]	否
meal	-1.990	[-10.760, +6.307]	否
music	-1.374	[-7.501, +5.138]	否
style	-5.362	[-12.470, +2.571]	否

style 的点估计方向最好，set→set 事件序列也有 -3.983 的点估计，但两者 CI 均跨 0。结合缺少固定 dev checkpoint accuracy/margin，当前不能声称任何主题或事件任务已经稳定学会。



10.5 异常样本候选审计

共有 3 个累积组超过一百万 raw gradient：step 256 (27,106,712)、step 179 (2,908,102) 和 step 11 (1,039,446)。step 256 比第二大值高 9.32 倍，其推导裁剪系数只有 3.689×10^{-8} 。

step 256 的 8 条候选如下：

位置	episode ID	topic	实际事件序列	updates	queries	mixed
1	r3-train-semantic-000103-s0-noop	style	set→noop→overwrite	3	2	0
2	r3-train-semantic-000262-s0-clean	drink	set→overwrite	2	2	0
3	r3-train-semantic-000139-s1-noop	meal	set→noop→overwrite	3	2	0
4	r3-train-semantic-000199-s1-clean	color	set→overwrite	2	2	0
5	r3-train-semantic-000831-s0-clean	material	set→set	2	3	1
6	r3-train-semantic-001046-s0-clean	drink	set→overwrite	2	3	1
7	r3-train-semantic-000463-s0-clean	drink	set→set	2	2	0
8	r3-train-semantic-001006-s0-noop	material	set→set→noop	3	2	0

该组平均 2.375 次 updater call，只有 2/8 mixed，没有 CLEAR；它不是长 episode 或 mixed episode 特别集中的组。完整的最高梯度 20 组、最高 loss 20 组及各自 160 条候选分别保存在：

- 最高梯度 20 组
- 最高梯度组的逐条候选
- 最高 loss 20 组
- 最高 loss 组的逐条候选

10.6 三个问题的当前答案

1. **哪类样本导致千万级梯度？** 只能锁定 step 256 的 8 条候选，不能在旧日志中定位单条。该组事件和长度组成普通，暂无证据把根因归给 CLEAR、NOOP、mixed 或长 episode。
2. **哪些任务实际上已经在学习？** 尚无可靠类别。style 和 **set→set** 只有方向性信号，置信区间均跨 0；没有固定 dev 基线就不能升级为学习结论。
3. **问题来自梯度尺度、数据难度还是多轮状态更新？** 当前证据优先支持“优化轨迹或梯度传播尺度”工作假设：loss-gradient 关联弱、极端组不长、梯度尾部在后期加重。多轮更新只有弱正关联且 Holm 校正后不显著；具体模块根因仍未测得。

10.7 尚未由本次旧日志补齐的项目

- **逐 episode 梯度与前 20 episode：** 必须对异常组候选逐条 **zero_grad → backward → record → discard**；旧日志无法逆推。
- **按模型模块梯度：** 正式 run 没有记录 **down/mid/up × q/k/v/out × LoRA A/B** 的 pre/post-clip norm，也没有实际 AdamW update/weight ratio。
- **固定 dev checkpoint 曲线：** 当前仍只有 step 256 的单一 dev loss；init、64、128、192、256 的 CE、accuracy、margin 必须从检查点补测。
- **因果评测：** blank、reset、matched state-swap、state shuffle 尚无完整终态结果，不能判断模型是否已经使用视觉状态。

因此，这一版报告已经完成了现有数据允许的最细粒度离线归因，并把千万级梯度缩小到可复查的 8 条候选；要继续收敛到单条样本和单个 LoRA block，必须使用新增梯度探针，不能继续从同一份聚合日志外推。